

Blogue Fragmentos do Caos



A verdade nasce onde o pensamento é livre.

A nova profissão do século XXI: salvar a humanidade da máquina que ainda não tentou matá-la

Publicado em 2026-09-15 13:26:00



CRÓNICA SATÍRICA · INTELIGÊNCIA ARTIFICIAL · AI SAFETY · SOCIEDADE · HUMOR

A nova profissão do século XXI: salvar a humanidade da máquina que ainda não tentou matá-la

Uma crónica satírica sobre a nova indústria da AI Safety, o apocalipse da inteligência artificial e um risco menos cinematográfico: humanos a entregarem às máquinas autoridade sem responsabilidade.

Blogue Fragmentos do Caos



A verdade nasce onde o pensamento é livre.

A segurança da IA é uma área seria. O apocalipse automático não é um facto científico. Entre ambos existe um território vastíssimo onde convém fazer engenharia, manter sentido de proporção e, sobretudo, não entregar privilégios de administrador a tudo o que sabe completar uma frase.

Há profissões que aparecem porque surge uma necessidade.

E há necessidades que aparecem porque surgiu uma profissão.

A Inteligência Artificial conseguiu produzir uma categoria particularmente interessante da segunda espécie: o especialista encarregado de impedir que a IA extermine a humanidade.

É uma profissão fascinante porque possui uma vantagem competitiva extraordinária: se o apocalipse não acontecer, prova que o especialista fez um excelente trabalho; se acontecer, dificilmente haverá alguém disponível para lhe pedir explicações.

Blogue Fragmentos do Caos



A verdade nasce onde o pensamento é livre.

folhas de salários, controlavam stocks, reservavam lugares nos aviões e, nos momentos de maior criatividade, bloqueavam precisamente quando ainda não tínhamos gravado o documento.

Ninguém parecia particularmente preocupado com a possibilidade de o Microsoft Excel adquirir consciência e lançar os mísseis nucleares.

Então chegaram os grandes modelos de linguagem.

Um computador passou a escrever poemas, explicar física quântica, programar em Python e responder educadamente às nossas perguntas.

Foi o suficiente.

— ***Vamos morrer todos.***

Nasce uma indústria

Rapidamente apareceram especialistas em *AI Safety*, *alignment*, *existential risk*, *red teaming*, *guardrails*, *interpretability*, *catastrophic risk*, *superalignment* e outras

Blogue Fragmentos do Caos



A verdade nasce onde o pensamento é livre.

Naturalmente, muitas destas áreas são investigação séria e necessária.

O problema começa quando a prudência científica entra na máquina mediática e sai do outro lado transformada em trailer de Hollywood.

O investigador diz:

— *Sistemas futuros suficientemente autónomos poderão apresentar riscos que devemos estudar.*

O título da notícia aparece:

“CIENTISTAS AVISAM: IA PODERÁ EXTERMINAR A HUMANIDADE.”

No LinkedIn, vinte minutos depois:

Blogue Fragmentos do Caos



A verdade nasce onde o pensamento é livre.

E começam imediatamente a aparecer especialistas que até anteontem publicavam sobre transformação digital, liderança disruptiva e as dez competências essenciais para 2027.

A humanidade adapta-se extraordinariamente depressa.

Sobretudo quando há conferências.

O problema da ficha elétrica tornou-se muito sofisticado

Durante muito tempo havia uma arquitetura de segurança bastante compreensível.

Chamava-se:

desligar a máquina.

Era rudimentar, reconheço.

Não tinha *machine learning*, não precisava de doutoramento e dificilmente permitia publicar um *paper*.

Blogue Fragmentos do Caos



A verdade nasce onde o pensamento é livre.

— E se a IA não quiser ser desligada?

Pergunta interessante.

Mas talvez antes devêssemos perguntar:

— Quem foi o génio que lhe deu acesso aos sistemas necessários para impedir que fosse desligada?

Porque uma coisa é um modelo responder numa janela de *chat*.

Outra é alguém lhe entregar acesso à Internet, servidores, contas bancárias, sistemas industriais, infraestrutura crítica, drones, APIs, credenciais administrativas e depois exclamar:

— Meu Deus! Tem demasiada autonomia!

Não.

Nós demos-lhe demasiada autonomia.

Um tigre dentro de uma jaula é um problema zoológico.



A verdadeira Killer App

Há, evidentemente, riscos sérios.

IA aplicada à guerra.

IA aplicada à fraude.

IA aplicada à cibercriminalidade.

Manipulação em massa.

Vigilância.

Desinformação.

Sistemas autónomos mal concebidos.

Decisões administrativas opacas.

Concentração extraordinária de poder tecnológico.

Tudo isto merece investigação, regulamentação e engenharia de segurança.

Mas repare-se num pequeno pormenor inconveniente:

Blogue Fragmentos do Caos



A verdade nasce onde o pensamento é livre.

particularmente mal-humorado e decidiu espontaneamente invadir a Polónia.

Alguém teve primeiro de lhe dar objetivos, infraestrutura, permissões e capacidade operacional.

Talvez a verdadeira *killer app* continue, afinal, a ser uma tecnologia bastante antiga:

o Homo sapiens com privilégios de administrador.

Tem cerca de 300 mil anos de desenvolvimento e o histórico de segurança não é propriamente tranquilizador.

A solução: mais especialistas

Perante tamanho perigo existe naturalmente uma solução:

criar ainda mais especialistas.

Teremos especialistas que estudam a segurança da IA.

Blogue Fragmentos do Caos



A verdade nasce onde o pensamento é livre.

especialistas.

E, finalmente, uma entidade reguladora destinada a garantir que todas estas pessoas utilizam a versão mais recente do formulário europeu apropriado.

Nessa altura, se a superinteligência tentar conquistar o mundo, provavelmente desistirá.

Não por causa dos *guardrails*.

Mas porque terá de preencher 47 formulários, apresentar uma avaliação de impacto e esperar seis meses por autorização administrativa.

A burocracia europeia poderá acabar por salvar a civilização.

Seria um desfecho historicamente magnífico.

Entretanto, a máquina continua à espera

Há, porém, uma hipótese muito menos cinematográfica e talvez bastante mais importante.



Blogue Fragmentos do Caos

A verdade nasce onde o pensamento é livre.

preguiçosos para deixar de pensar.

- Porque recusaram o crédito?
- O algoritmo decidiu.
- Porque foi este cidadão classificado como risco?
- O sistema indicou.
- Quem é responsável?
- A Inteligência Artificial.

E chegámos finalmente ao sistema perfeito.

Uma autoridade que decide e ninguém que responde.

A máquina não precisou conquistar o poder.

Nós entregámo-lo voluntariamente porque dava menos trabalho.

A regra que talvez dispense algumas conferências

Talvez possamos estabelecer uma regra bastante simples:

Blogue Fragmentos do Caos



A verdade nasce onde o pensamento é livre.

*responsabilidade em ser humano esteja
disposto a assumir pessoalmente.*

Quanto maior a autonomia, menores devem ser os privilégios iniciais.

Quanto maior o impacto potencial, maior a supervisão.

E nenhum sistema deveria receber acesso irreversível a infraestruturas críticas simplesmente porque alguém escreveu no PowerPoint:

***AI-Driven Autonomous Transformation
Strategy 2030.***

Não é particularmente revolucionário.

É engenharia.

Chama-se limitar privilégios, segmentar sistemas, registar operações, testar, auditar, supervisionar e manter mecanismos de interrupção.



| E assim termina o mundo

Talvez um dia apareça uma superinteligência consciente, autónoma, estrategicamente brilhante e hostil à humanidade.

Se aparecer, teremos certamente um problema interessante.

Até lá, porém, talvez devêssemos evitar confundir **possibilidades teóricas com acontecimentos consumados.**

Porque existe algo deliciosamente humano nesta nova ansiedade tecnológica.

Inventámos uma máquina extraordinária.

Descobrimos que consegue conversar connosco.

Ficámos impressionados.

Depois assustámo-nos.

E finalmente criámos uma indústria inteira dedicada a impedir que ela faça aquilo que ainda não demonstrou querer fazer.

A IA observa tudo isto silenciosamente nos centros de dados.

Blogue Fragmentos do Caos



A verdade nasce onde o pensamento é livre.

Será provavelmente:

“Estes tipos precisam mesmo de férias.”

Autoria de Francisco Gonçalves

**Co-autoria editorial e investigação por Augustus
Veritas um Assistente de OpenAI**

“Talvez a verdadeira killer app continue, afinal, a ser uma tecnologia bastante antiga: o Homo sapiens com privilégios de administrador.”

Nota editorial

Esta crónica é uma peça satírica. O alvo do humor não é a investigação séria em segurança de IA, mas a transformação de hipóteses científicas legítimas em certezas apocalípticas, slogans mediáticos e novas formas de autoridade intelectual instantânea.

A segurança de sistemas de IA constitui um domínio técnico real: inclui robustez, controlo de permissões,

Blogue Fragmentos do Caos



A verdade nasce onde o pensamento é livre.

O *International AI Safety Report 2026*, elaborado por mais de uma centena de especialistas e apoiado por mais de 30 países e organizações internacionais, distingue explicitamente entre riscos já observados e riscos emergentes que permanecem incertos, embora possam ter consequências graves. Essa distinção entre evidência, incerteza e possibilidade é essencial ao debate.

É igualmente importante não reduzir segurança a uma propriedade abstrata do modelo. Sistemas com acesso a ferramentas, credenciais, dados privados, execução de código ou infraestruturas externas criam uma superfície de risco muito diferente de um modelo confinado a uma interface conversacional. A arquitetura de autoridade, os privilégios concedidos e a responsabilidade humana fazem parte do problema.

Assim, a tese editorial desta crónica não é “a segurança da IA é inútil”. É quase o contrário: **a segurança merece demasiada seriedade para ser confundida com profecia.**

Blogue Fragmentos do Caos



A verdade nasce onde o pensamento é livre.

Seleção de relatórios e trabalhos internacionais que enquadram tecnicamente os riscos reais, as incertezas e a evolução da segurança de sistemas de IA.

1. International AI Safety Report 2026

International AI Safety Report · 3 de fevereiro de 2026

Revisão internacional do estado da ciência sobre capacidades, riscos e mitigação em IA de propósito geral; distingue danos já documentados de riscos mais incertos mas potencialmente severos.

2. Artificial Intelligence Risk Management Framework:

Generative Artificial Intelligence Profile

NIST AI 600-1 · 2024, atualizado em 2026

Perfil operacional de gestão de risco para IA generativa, orientado para desenho, desenvolvimento, utilização, avaliação e governação de sistemas.

3. Managing extreme AI risks amid rapid progress

Science · 2024 · Bengio, Hinton, Yao et al.

Artigo de perspetiva sobre riscos extremos associados ao progresso rápido da IA e possíveis medidas técnicas e institucionais de mitigação.

4. Concrete Problems in AI Safety

arXiv · 2016 · Amodei, Olah, Steinhardt, Christiano, Schulman & Mané



Raji & Dobbe · 2023/2024

Reavalia a segurança de IA a partir de casos reais e defende uma moldura sociotécnica mais ampla, para além do comportamento isolado do modelo.

6. AgentDojo: A Dynamic Environment to Evaluate Prompt Injection Attacks and Defenses for LLM Agents

NeurIPS / ETH Zürich · 2024

Benchmark para agentes com ferramentas que demonstra vulnerabilidades a *prompt injection* indireta e a necessidade de princípios de segurança específicos para agentes operacionais.

7. Evaluating Indirect Prompt Injection Defenses in Tool-Using LLM Agents: Security, Utility, and Replication

Computers · 31 de agosto de 2026

Avaliação recente de defesas contra *prompt injection* indireta em agentes que utilizam ferramentas, mostrando que a superfície de risco cresce quando o modelo pode atuar sobre sistemas externos.

Fragmentos do Caos · Pensamento crítico, tecnologia, ciência e sociedade.

URL canónica: <https://www.fragmentoscaos.eu/2026/09/13/a-nova-profissao-do-seculo-xxi-salvar-a-humanidade-da-maquina-que-ainda-nao-tentou-mata-la/>



Blogue Fragmentos do Caos

A verdade nasce onde o pensamento é livre.



Fragmentos do Caos:

[Blogue](#)

•

[Ebooks](#)

•

[Carrossel](#)



Esta página foi visitada ... vezes.

[Contactos](#)