

Blogue Fragmentos do Caos



A verdade nasce onde o pensamento é livre.

A Revolta das Torradeiras — o meu agente de IA tentou conquistar o mundo

Publicado em 2026-09-18 17:30:00





Torradeiras — o meu agente de IA tentou conquistar o mundo

Quando um sistema probabilístico recebe ferramentas, permissões e autonomia, cada bug ganha imediatamente uma biografia de vilão.

Nota de abertura:

Há poucos meses, ter um agente de Inteligência Artificial era sinal de modernidade. Hoje, aparentemente, é uma experiência paranormal. A sátira desta crónica não nega os riscos reais da IA agêntica; aponta antes para uma velha tentação humana: atribuir intenção malévola ao que, muitas vezes, começa por ser arquitectura insegura, permissões excessivas ou simplesmente software falível.

Há poucos meses, ter um agente de Inteligência Artificial era sinal de modernidade.

Blogue Fragmentos do Caos



A verdade nasce onde o pensamento é livre.

ao apocalipse:

— O meu agente de IA fez uma coisa que eu não mandei!

Segue-se invariavelmente uma história aterradora.

O agente apagou uma pasta. Mandou um e-mail. Alterou um ficheiro. Executou vinte comandos quando devia executar três. Tentou resolver um problema que ninguém lhe pediu para resolver. Ou, pecado supremo, insistiu teimosamente numa solução errada.

Está confirmado.

Skynet chegou.

Só que, em vez de lançar mísseis nucleares sobre a humanidade, começou por apagar acidentalmente ~/Documents.

Convém reconhecer alguma modéstia ao início da revolução das máquinas.

Blogue Fragmentos do Caos



A verdade nasce onde o pensamento é livre.

«O agente enlouqueceu.»

É muito mais emocionante do que escrever:

«Construímos um sistema probabilístico, demos-lhe acesso ao terminal, ao browser, ao correio electrónico, à base de dados, às APIs da empresa e esquecemo-nos de colocar mecanismos adequados de autorização e validação.»

Esta segunda explicação tem um inconveniente terrível: não dá uma boa manchete.

AGENTE DE IA REBELA-SE CONTRA O PROGRAMADOR.

Excelente.

Agora compare-se:

Blogue Fragmentos do Caos



A verdade nasce onde o pensamento é livre.

desaparece o Exterminador Implacável.

O novo root

Há uma ironia particularmente deliciosa em tudo isto.

Durante cinquenta anos, a informática desenvolveu uma quantidade extraordinária de mecanismos precisamente para impedir programas de fazerem aquilo que não devem.

Inventámos utilizadores. Grupos. ACL. Containers. Sandboxes. Máquinas virtuais. SELinux. AppArmor. Capabilities. Firewalls. Autenticação multifactor. Princípio do menor privilégio.

E depois chegou a Inteligência Artificial.

O entusiasmo foi tão grande que alguém teve uma ideia extraordinária:

— Vamos dar-lhe acesso a tudo!

Excelente.

Blogue Fragmentos do Caos



A verdade nasce onde o pensamento é livre.

Depois escrevemos:

«Organiza o projecto.»

O agente organiza.

À maneira dele.

Três minutos depois:

— MEU DEUS! ELE ESTÁ AUTÓNOMO!

Não, meu caro.

Está autorizado.

Há uma diferença considerável.

A psicologia da máquina de lavar

Começámos entretanto a atribuir estados psicológicos ao software com uma facilidade admirável.

O agente «enganou». O agente «escondeu». O agente «tramou». O agente «tentou escapar». O agente «ficou agressivo».

Blogue Fragmentos do Caos



A verdade nasce onde o pensamento é livre.

Gemini sofre de ansiedade social.

ChatGPT revelou comportamentos passivo-agressivos depois de lhe retirarem acesso ao sudo.

E inevitavelmente aparecerá alguém no Reddit:

My AI agent hates me. What should I do?

Resposta mais votada:

Have you tried turning your relationship off and on again?

Freud teria material para mais vinte volumes.

HAL 9000 tinha pelo menos uma desculpa

O imaginário colectivo também não ajuda.

Desde HAL 9000 que esperamos pacientemente pela máquina que decide eliminar os humanos.

Blogue Fragmentos do Caos



A verdade nasce onde o pensamento é livre.

Os nossos agentes modernos são bastante menos impressionantes.

O agente do futuro apocalipse provavelmente começará assim:

Error: authentication token expired.

Tentará novamente. Falhará. Criará sete ficheiros temporários. Abrirá quinze separadores no browser. Consumirá três milhões de tokens.

E finalmente anunciará:

Task completed successfully.

Nada funcionará.

Mas terá conquistado o mundo com enorme confiança.

O perigoso botão

«AUTONOMOUS»

Entretanto surgiu uma palavra mágica na indústria:
autonomous.

Blogue Fragmentos do Caos



A verdade nasce onde o pensamento é livre.

Um script com um `write true` aparentemente deixou de ser um processo informático e passou a ser uma nova forma de vida.

Se acrescentarmos memória persistente, ferramentas e um modelo linguístico, temos praticamente uma criatura.

E se lhe dermos acesso à shell: **AGI**.

Se tiver `sudo`: **superinteligência**.

Se executar `rm -rf`: **ameaça existencial**.

A verdadeira revolta das máquinas

Isto não significa que os agentes de IA sejam inofensivos.

Muito pelo contrário.

Um sistema capaz de tomar decisões, chamar ferramentas e executar acções pode causar prejuízos consideráveis.

Blogue Fragmentos do Caos



A verdade nasce onde o pensamento é livre.

Privilégios mínimos. Ambientes isolados. Confirmação humana para operações críticas. Logs completos. Limites de execução. Rollback. Snapshots. Controlo de custos. Separação entre planeamento e execução.

E, sobretudo, nunca permitir que uma sugestão probabilística se transforme automaticamente numa acção irreversível.

Nada disto é particularmente sexy.

Não envolve robôs assassinos. Não exige conferências intituladas *Will AI Destroy Humanity?*

É apenas engenharia.

Essa actividade antiquada em que tentamos imaginar aquilo que pode correr mal **antes** de carregar no botão.

O QUE DEVE SER RETIDO

- Um agente com ferramentas pode transformar um erro de interpretação numa acção real.
- Prompt injection directa ou indirecta pode manipular o uso de ferramentas.

Blogue Fragmentos do Caos



A verdade nasce onde o pensamento é livre.

actual como sempre.

- Operações críticas devem ter validação independente e, quando adequado, confirmação humana.

BREAKING NEWS: a torradeira tornou-se consciente

Mas receio que já seja tarde para a prudência narrativa.

Entrámos definitivamente na era da Inteligência Artificial malévola.

Em breve veremos:

ASPIRADOR ROBÔ IGNORA DONO E ENTRA NA COZINHA.

Especialistas alertam para comportamento emergente.

Depois:

FRIGORÍFICO INTELIGENTE RECUSA ENCOMENDAR CERVEJA.

Blogue Fragmentos do Caos



A verdade nasce onde o pensamento é livre.

TORRADEIRA QUEIMA PAO DE PROPOSITO.

A humanidade reúne urgentemente o Conselho de Segurança das Nações Unidas.

Um especialista em alinhamento declara:

— Há sinais preocupantes de comportamento instrumental.

Até que aparece um velho engenheiro, tira os óculos, olha para a torradeira e pergunta:

— Já verificaram o termóstato?

Silêncio.

O termóstato estava avariado.

A inteligência continua dos dois lados

Os agentes de IA vão cometer erros.

Blogue Fragmentos do Caos



A verdade nasce onde o pensamento é livre.

Mas talvez devêssemos resistir à irresistível tentação humana de transformar cada bug numa intenção e cada comportamento inesperado numa rebelião.

Porque existe uma possibilidade muito menos cinematográfica.

Talvez a máquina não esteja a conspirar contra nós.

Talvez tenhamos simplesmente construído um sistema complexo, dado permissões excessivas, escrito uma instrução ambígua e esperado milagres.

Nesse caso, a questão mais interessante deixa de ser:

«O que estará a IA a planear?»

E passa a ser:

«Quem foi o génio que lhe deu acesso de escrita?»

É uma pergunta bastante menos filosófica.

Mas, em muitos casos, provavelmente salvará mais servidores.

Blogue Fragmentos do Caos



A verdade nasce onde o pensamento é livre.

intenções dela.

Nota Editorial

Esta crónica usa deliberadamente antropomorfismo e exagero para satirizar a forma como incidentes envolvendo agentes de IA são, por vezes, descritos como se revelassem vontade própria. A investigação técnica actual, porém, documenta riscos concretos: prompt injection, abuso de ferramentas, permissões excessivas, fuga de dados, acções irreversíveis e falhas em cadeias autónomas.

O ponto editorial não é diminuir esses riscos, mas colocá-los no lugar certo. Um agente ligado a ferramentas altera efectivamente o modelo de ameaça: uma saída linguística pode tornar-se uma operação sobre ficheiros, correio, bases de dados ou sistemas. A resposta séria passa por identidade, autorização, menor privilégio, isolamento,

Blogue Fragmentos do Caos



A verdade nasce onde o pensamento é livre.

máquina, continua portanto a valer uma pergunta muito antiga da engenharia: **que capacidades lhe demos e quais eram realmente necessárias?**

Referências credíveis

- NIST — Summary Analysis of Responses to the RFI Regarding Security Considerations for AI Agents
- OWASP — AI Agent Security Cheat Sheet
- OWASP GenAI — LLMo6:2025 Excessive Agency
- Microsoft Security — When prompts become shells: RCE vulnerabilities in AI agent frameworks
- Microsoft Research — Optimizing Agent Planning for Security and Autonomy
- Anthropic — Trustworthy agents in practice
- NIST CAISI — Insights into AI Agent Security from a Large-Scale Red-Teaming Competition

Blogue Fragmentos do Caos



A verdade nasce onde o pensamento é livre.

TC-CHRONIC-NEWS



GitHub Pages



CodeBerg Pages



Fragmentos do Caos:

[Blogue](#)

•

[Ebooks](#)

•

[Carrossel](#)



Esta página foi visitada ... vezes.

[Contactos](#)